Resumen de temas del trimestre I

Nayelis Fernanda David Goez

Servicio Nacional de Aprendizaje (SENA)

Centro de Materiales y Ensayos

Procesamiento de Datos para Modelos de Inteligencia Artificial

Ficha 3533558

Ing. Nathalia Martinez Vargas

31 de octubre de 2026

Resumen de temas del trimestre I

Índice

Presentación **3**

Actividades **3**

Reflexión inicial 3

Pregunta 1 3

Pregunta 2 3

Pregunta 3 4

Pregunta 4 4

Contextualización del conjunto de datos 4

Descripción y relevancia 4

Preguntas de negocio 4

Actividades de apropiación 5

Caracterización de variables 5

Limpieza de datos 5

Análisis exploratorio de datos 5

Actividades de transferencia del conocimiento 5

Pregunta 1: localidad con más muertes 5

Pregunta 2: evolución de la tasa de mortalidad 6

Pregunta 3: población infantil y muertes por localidad 7

Referencias **17**

Presentación

Este documento presenta un repaso de los temas del trimestre I del programa técnico en Procesamiento de Datos para Modelos de Inteligencia Artificial. La preparación de datos es fundamental para obtener análisis confiables: incluso un algoritmo adecuado puede producir resultados engañosos si se alimenta con datos incompletos, inconsistentes o mal interpretados.

El trabajo se organiza en cuatro ejes: identificación de fuentes y formatos; consulta de bases de datos relacionales mediante SQL; exploración de datos con Python y Pandas; y limpieza y análisis exploratorio de datos (EDA). Estos procesos se aplican a un conjunto de datos sobre mortalidad en menores de cinco años por localidad y año en Bogotá.

Actividades

Reflexión inicial

Las siguientes respuestas relacionan la calidad, la comprensión y la documentación de los datos con el caso de la sonda Mars Climate Orbiter. La investigación del incidente destacó la importancia de verificar la compatibilidad de las unidades y de documentar correctamente los datos y procesos (Jet Propulsion Laboratory, 1999; Mars Climate Orbiter Mishap Investigation Board, 2000; NASA, s. f.).

Pregunta 1

Si una empresa registra ventas en pesos como si fueran dólares, sus reportes podrían mostrar cantidades superiores a las reales. Con base en esa información, podría tomar decisiones equivocadas, como gastar de más o sobreestimar sus ingresos. Por ello, antes de realizar cálculos, verificaría la moneda y las unidades de los valores.

Pregunta 2

El diccionario de datos es importante porque explica qué significa cada columna, qué tipo de dato contiene y en qué unidades está expresada. Esta documentación evita tener que adivinar al trabajar con Python o SQL. El caso de la sonda Mars Climate Orbiter muestra cómo una interpretación incorrecta de las unidades puede contribuir a errores importantes (Jet Propulsion

Laboratory, 1999; Mars Climate Orbiter Mishap Investigation Board, 2000).

Pregunta 3

Antes de procesar un archivo, elaboraría un diccionario de datos para describir cada columna, su propósito, su tipo y sus unidades. También revisaría una muestra de registros para confirmar la interpretación de las variables. Así comprendería el contenido del archivo antes de realizar cálculos o transformaciones.

Pregunta 4

Tener millones de registros no garantiza un análisis útil si no se comprende qué representan. Una interpretación incorrecta de las columnas o sus unidades puede llevar a conclusiones equivocadas, aunque se disponga de muchos datos. Las herramientas facilitan el procesamiento, pero primero es necesario comprender la información.

Contextualización del conjunto de datos

Descripción y relevancia

El conjunto de datos seleccionado se titula *Mortalidad en menores de 5 años por localidad y año*. Proviene de Datos Abiertos Bogotá y contiene registros organizados por año y localidad, además de variables relacionadas con las muertes registradas, la población infantil y la tasa de mortalidad por cada 100.000 menores de cinco años (Secretaría Distrital de Salud, s. f.). El periodo indicado en el archivo comprende registros desde 2015 y proyecciones hasta 2026.

La información se atribuye al Observatorio de Salud Sexual y Reproductiva y a las entidades distritales de salud. Su análisis permite describir la distribución temporal y territorial de la mortalidad infantil en Bogotá. Estos resultados pueden apoyar la identificación de zonas que requieren atención, aunque los conteos absolutos deben interpretarse junto con el tamaño de la población y las tasas correspondientes.

Preguntas de negocio

A partir de las variables disponibles, se plantean las siguientes preguntas:

1. ¿Qué localidad registra el mayor número total de muertes de menores de cinco años en el

periodo analizado?

2. ¿Cómo ha evolucionado año tras año la tasa de mortalidad por cada 100.000 menores de cinco años en Bogotá?

3. ¿Qué diferencias se observan entre la población infantil promedio y el número de muertes por localidad?

Actividades de apropiación

Caracterización de variables

La Figura 1 presenta el diccionario elaborado para describir las variables, sus tipos y sus características.

Limpieza de datos

El proceso de limpieza incluyó la lectura del archivo CSV con el separador correspondiente, la eliminación de columnas vacías o sin nombre y la revisión de valores faltantes y registros duplicados. Además, se convirtió la tasa de mortalidad a un tipo numérico para facilitar el análisis. Las Figuras 2 a 4 documentan estas etapas.

Análisis exploratorio de datos

La exploración incluyó el cálculo de estadísticas descriptivas, la visualización de la distribución de la tasa de mortalidad y la identificación de las localidades con mayores conteos acumulados. Las Figuras 5 a 10 muestran el código y los resultados gráficos utilizados.

Actividades de transferencia del conocimiento

Las consultas SQL se utilizaron para responder las preguntas de negocio. Las capturas de pantalla documentan la creación de la tabla y las consultas aplicadas; los resultados se resumen a continuación.

Pregunta 1: localidad con más muertes

La Figura 11 muestra la definición de la tabla utilizada, y la Figura 12 presenta la consulta para agrupar las muertes por localidad y ordenar los resultados de mayor a menor.

Figura 1

Diccionario de variables del conjunto de datos.

Diccionario de datos del archivo obs_salud_sexual_reproductiva-mortalidad.csv (Datos Abiertos Bogotá - Mortalidad en menores de 5 años por localidad y año).

Columna	Tipo de dato en lenguaje natural	Tipo de dato declaración	Que significa el dato en el archivo
Año	Cualitativo/Temporal	String/int	Determina el año calendario en el que se realizó el registro u observación estadística.
Localidad	cualitativo	String	Se refiere a la localidad del Distrito Capital de Bogotá a la que pertenece el registro.
Muertes	cuantitativo	Int / (Entero)	Número total de defunciones registradas en menores de 5 años.
Denominador poblacional	cuantitativo	Float (Decimal)	Representa la población total estimada de menores de 5 años en esa localidad y año.
Tasa por 100.000 menores de 5 años	Cuantitativo	String / float	Indicador epidemiológico que mide la proporción de muertes por cada 100.000 niños menores de 5 años.

Nota. Elaboración propia a partir del conjunto de datos de mortalidad infantil de Bogotá.

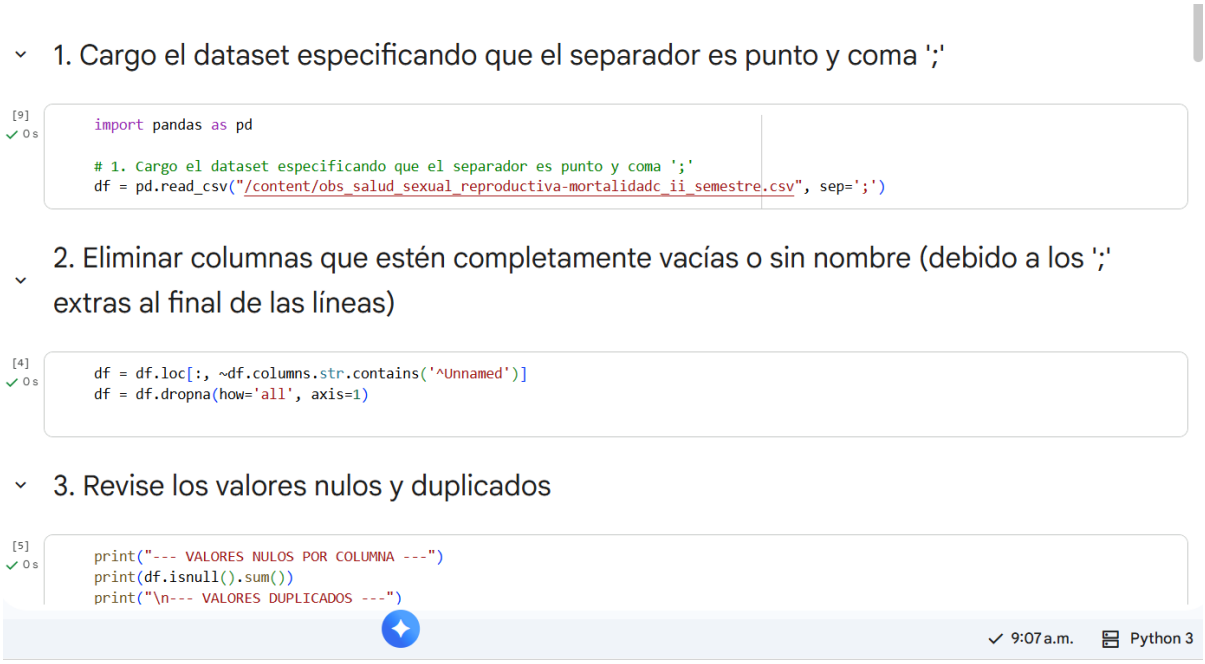
Según el resultado reportado, Kennedy registra el mayor número acumulado de muertes en menores de cinco años, con más de 1.200 casos en el periodo analizado. Este conteo puede orientar una revisión territorial, pero debe interpretarse junto con el tamaño de la población y las tasas locales.

Pregunta 2: evolución de la tasa de mortalidad

La Figura 13 presenta la consulta para revisar la tasa por año. La serie muestra una tendencia fluctuante, con picos en años específicos. Para determinar las causas de esos cambios sería necesario complementar la consulta con información contextual sobre la cobertura y el acceso a los servicios de salud.

Figura 2

Lectura del archivo y depuración de columnas vacías.



Nota. Elaboración propia a partir del conjunto de datos de mortalidad infantil de Bogotá.

Pregunta 3: población infantil y muertes por localidad

La Figura 14 presenta la consulta que compara el promedio de población infantil con el total de muertes por localidad. Los conteos absolutos tienden a ser mayores en localidades con más población; sin embargo, por sí solos no indican un mayor riesgo. Para comparar el riesgo entre localidades se deben considerar las tasas y sus denominadores.

Declaración sobre el uso de inteligencia artificial

Para la elaboración de esta guía se utilizó Gemini (Google) como herramienta de apoyo en aproximadamente el 15 % del proceso. Se empleó en la estructuración de las preguntas de negocio y la definición de tipos de datos, así como en la revisión de la sintaxis de consultas SQL y de operaciones básicas de limpieza en Pandas. El análisis crítico, la ejecución en las herramientas y la integración final del reporte fueron revisados y validados por la aprendiz Nayelis Fernanda David Goez.

Figura 3

Revisión de valores faltantes, duplicados y conversión de la tasa.



Nota. Elaboración propia a partir del conjunto de datos de mortalidad infantil de Bogotá.

Figura 4

Vista previa del conjunto de datos después de la limpieza.



```
[15]
✓ 0 s
df[col_name] = df[col_name].astype(str).str.replace(',', '.').astype(float)
```

5. Vista previa del resultado limpio

```
[14]
✓ 0 s
print("\n--- PRIMERAS FILAS DEL DATAFRAME LIMPIO ---")
print(df.head())
```

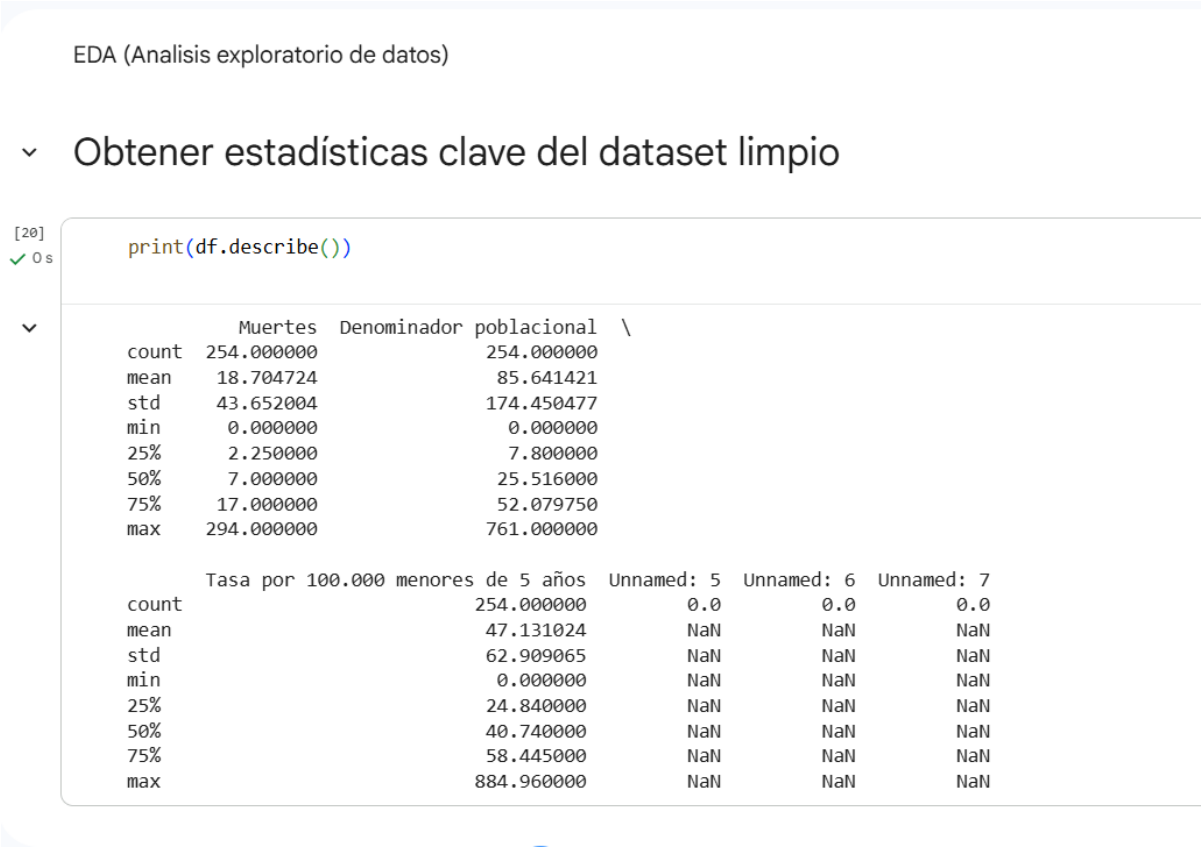
```
--- PRIMERAS FILAS DEL DATAFRAME LIMPIO ---
    Año      Localidad  Muertes  Denominador poblacional  \
0  2015         Bogotá      294                  484.506
1  2015        Usaquén       18                   28.764
2  2015      Chapinero        6                    7.623
3  2015       Santa Fe        2                    6.961
4  2015  San Cristóbal       25                   28.900

   Tasa por 100.000 menores de 5 años  Unnamed: 5  Unnamed: 6  Unnamed: 7
0                               60.68         NaN         NaN         NaN
1                               62.58         NaN         NaN         NaN
2                               78.71         NaN         NaN         NaN
3                               28.73         NaN         NaN         NaN
4                               86.51         NaN         NaN         NaN
```

Nota. Elaboración propia a partir del conjunto de datos de mortalidad infantil de Bogotá.

Figura 5

Estadísticas descriptivas del conjunto de datos limpio.



Nota. Elaboración propia a partir del conjunto de datos de mortalidad infantil de Bogotá.

Figura 6

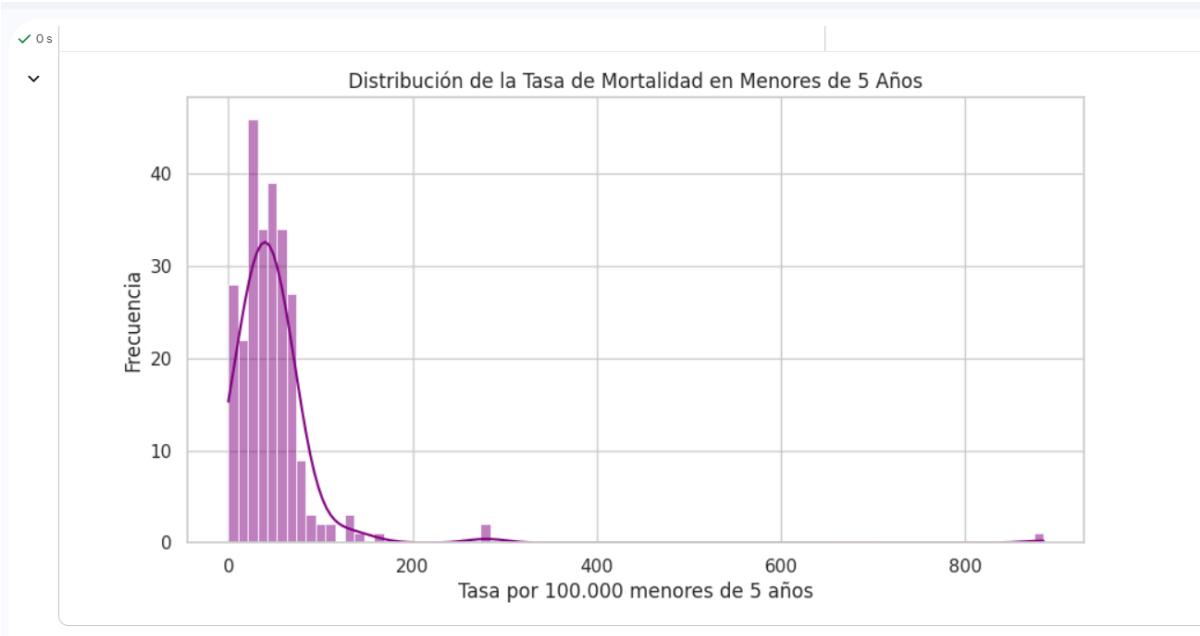
Código para generar el histograma y la curva de densidad de la tasa.



Nota. Elaboración propia a partir del conjunto de datos de mortalidad infantil de Bogotá.

Figura 7

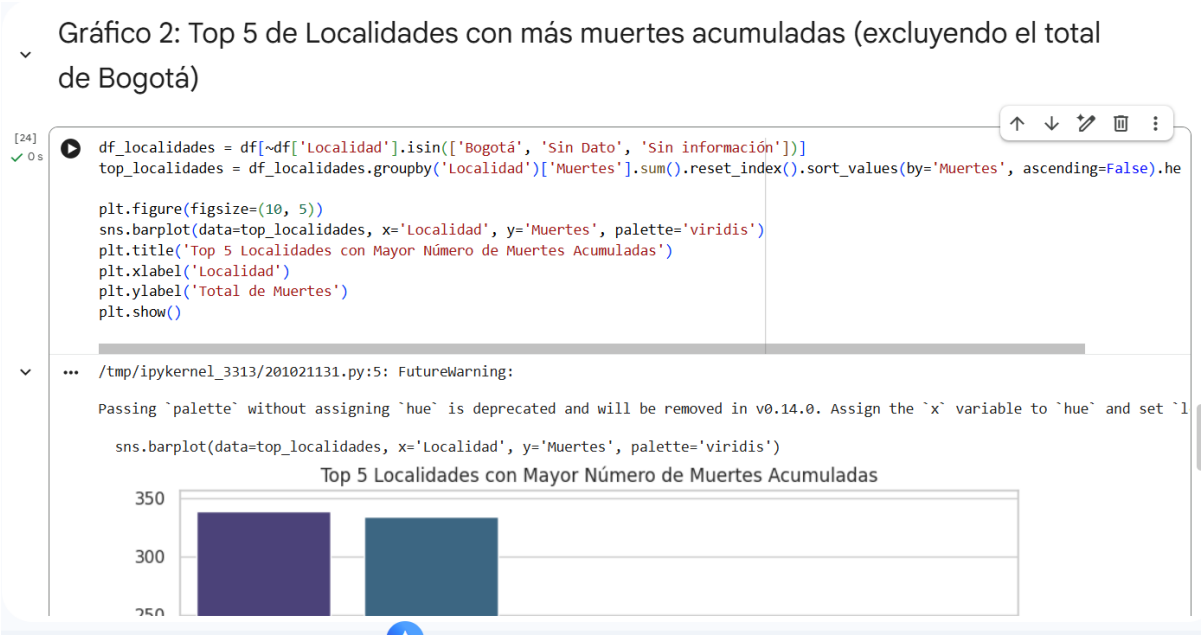
Distribución de la tasa de mortalidad en menores de cinco años.



Nota. Elaboración propia a partir del conjunto de datos de mortalidad infantil de Bogotá.

Figura 8

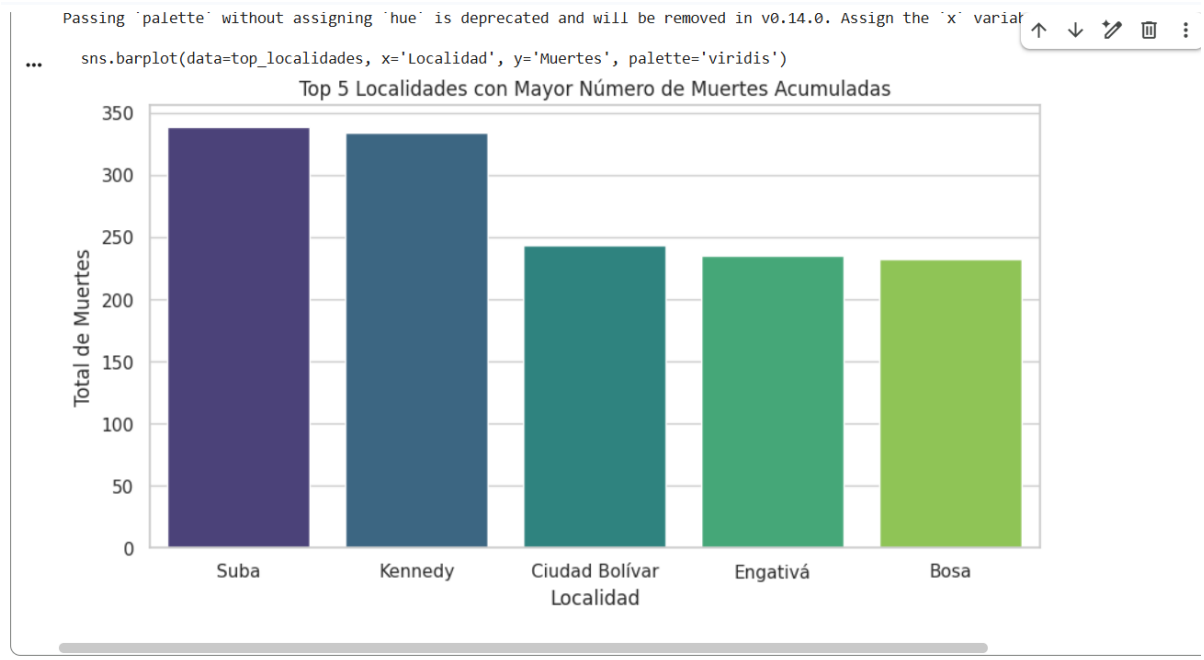
Código para identificar las cinco localidades con más muertes acumuladas.



Nota. Elaboración propia a partir del conjunto de datos de mortalidad infantil de Bogotá.

Figura 9

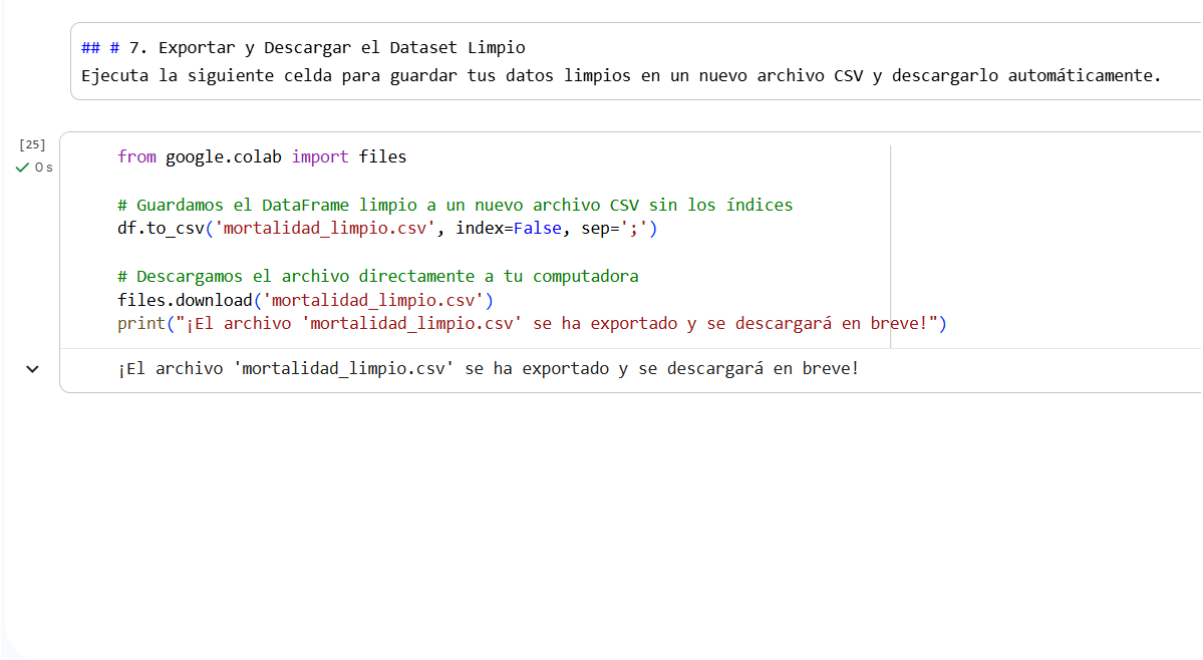
Muertes acumuladas en las cinco localidades con los mayores valores.



Nota. Elaboración propia a partir del conjunto de datos de mortalidad infantil de Bogotá.

Figura 10

Código para exportar el conjunto de datos limpio.



```
## # 7. Exportar y Descargar el Dataset Limpio
Ejecuta la siguiente celda para guardar tus datos limpios en un nuevo archivo CSV y descargarlo automáticamente.
```

```
[25]
✓ 0 s
```

```
from google.colab import files

# Guardamos el DataFrame limpio a un nuevo archivo CSV sin los índices
df.to_csv('mortalidad_limpio.csv', index=False, sep=';')

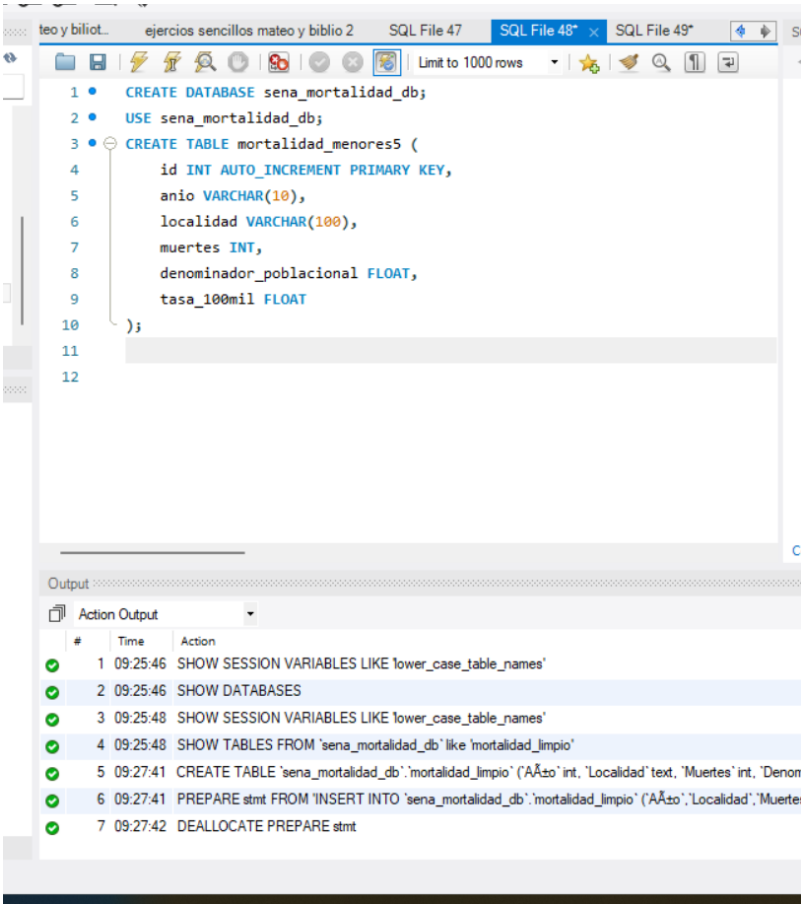
# Descargamos el archivo directamente a tu computadora
files.download('mortalidad_limpio.csv')
print("¡El archivo 'mortalidad_limpio.csv' se ha exportado y se descargará en breve!")
```

```
¡El archivo 'mortalidad_limpio.csv' se ha exportado y se descargará en breve!
```

Nota. Elaboración propia a partir del conjunto de datos de mortalidad infantil de Bogotá.

Figura 11

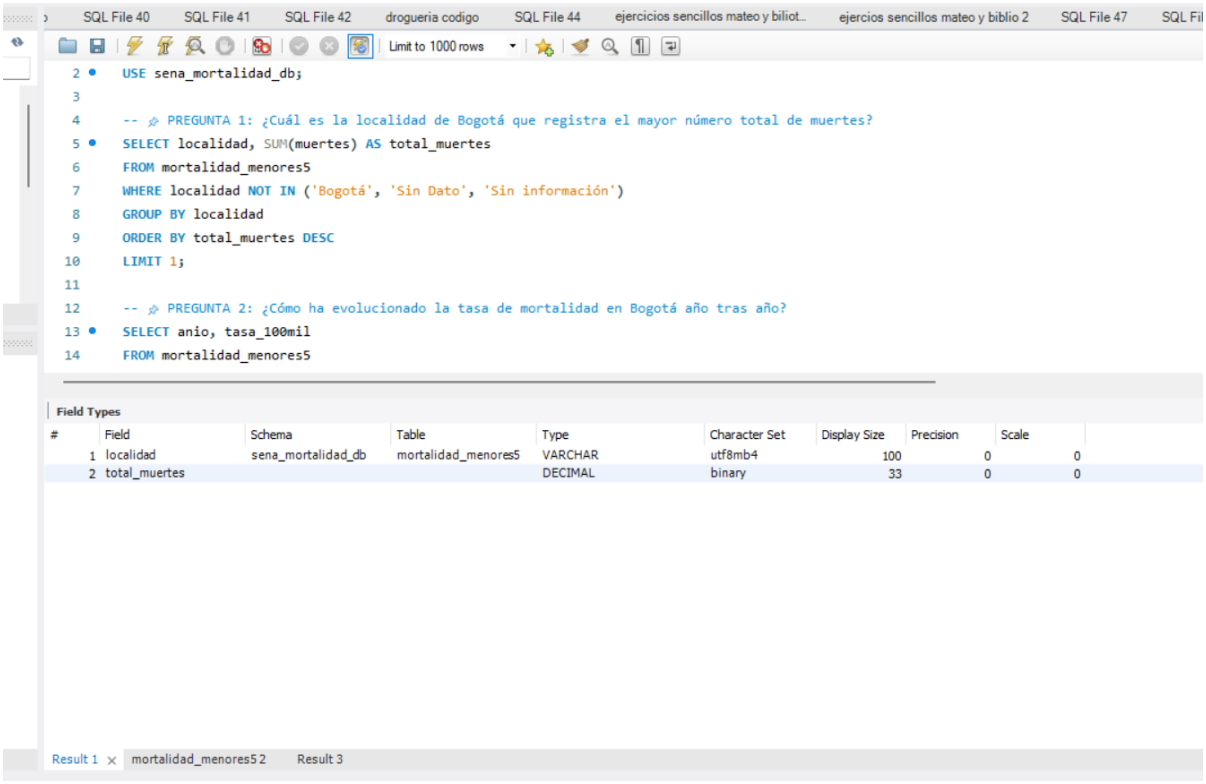
Estructura de la tabla para almacenar los datos de mortalidad.



Nota. Elaboración propia a partir del conjunto de datos de mortalidad infantil de Bogotá.

Figura 12

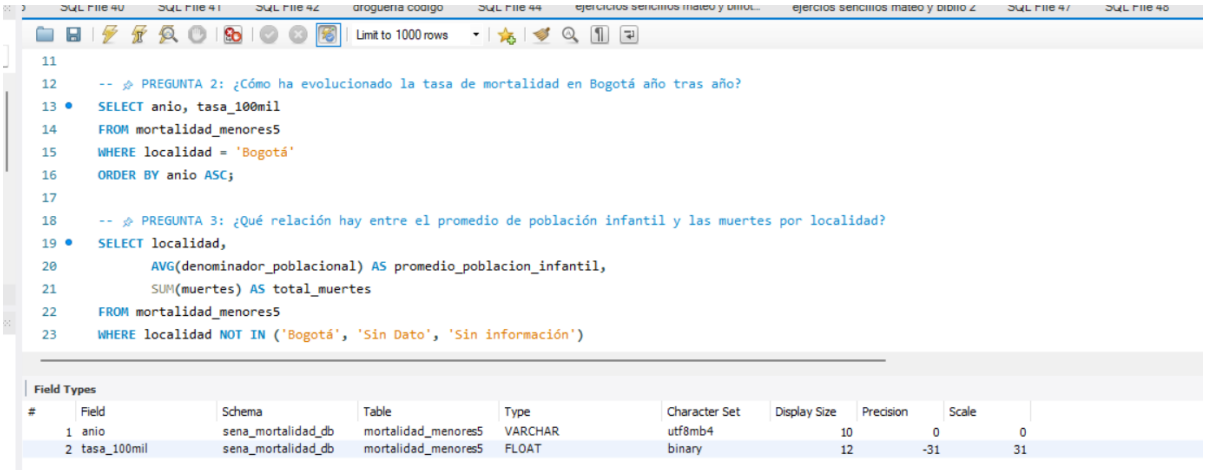
Consulta SQL para identificar la localidad con más muertes.



Nota. Elaboración propia a partir del conjunto de datos de mortalidad infantil de Bogotá.

Figura 13

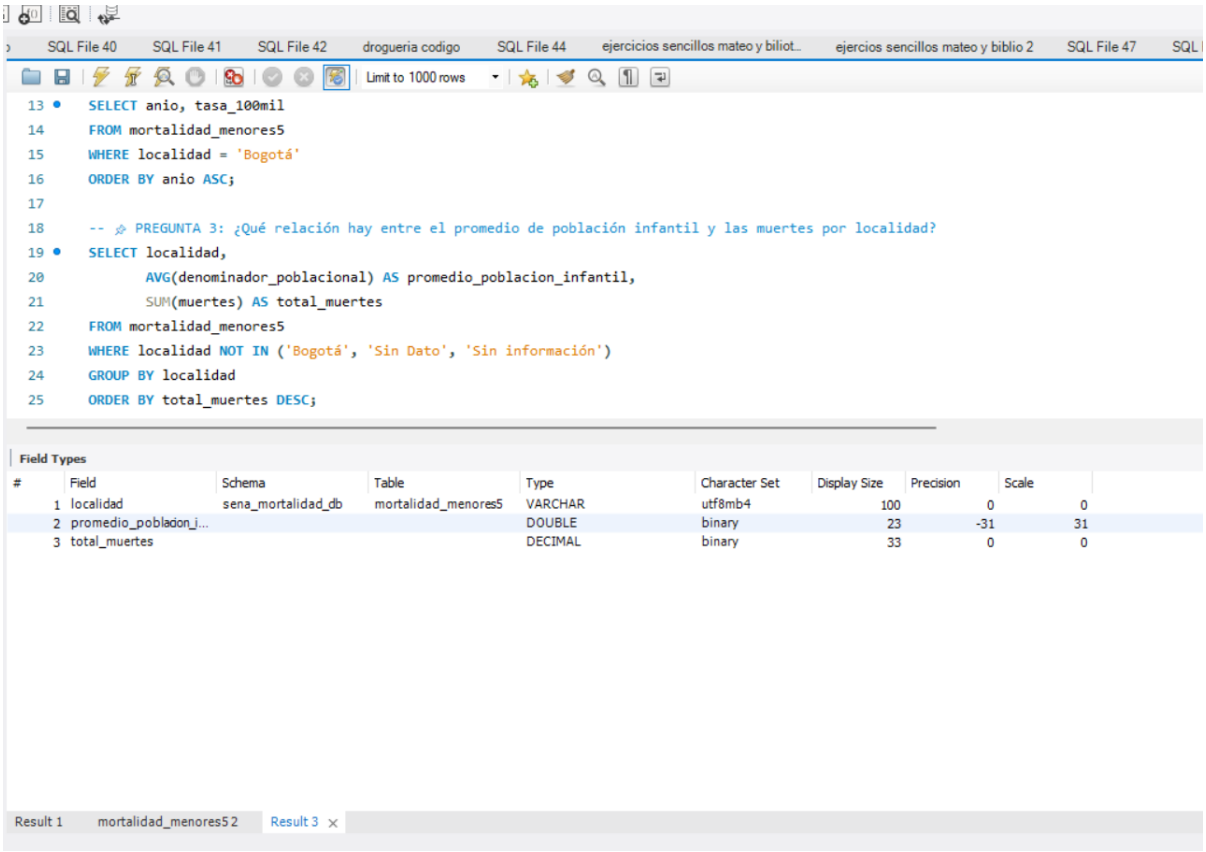
Consultas SQL para revisar la tasa anual y la población infantil promedio.



Nota. Elaboración propia a partir del conjunto de datos de mortalidad infantil de Bogotá.

Figura 14

Consulta SQL para comparar la población infantil promedio y las muertes por localidad.



Nota. Elaboración propia a partir del conjunto de datos de mortalidad infantil de Bogotá.

Referencias

Jet Propulsion Laboratory. (1999, 30 de septiembre). *Mars Climate Orbiter team finds likely cause of loss*. NASA. https://www.jpl.nasa.gov/news/mars-climate-orbiter-team-finds-likely-cause-of-loss/

Mars Climate Orbiter Mishap Investigation Board. (2000). *Report on project management in NASA by the Mars Climate Orbiter Mishap Investigation Board (Phase II report)*. NASA. https://discovery.larc.nasa.gov/discovery/PDF_FILES/mars_climate_orbiter_phaseII.pdf

NASA. (s. f.). *Mars Climate Orbiter*. NASA Science. https://science.nasa.gov/mission/mars-climate-orbiter/

Secretaría Distrital de Salud. (s. f.). *Mortalidad en menores de 5 años por localidad y año* [Conjunto de datos]. Datos Abiertos Bogotá. https://datosabiertos.bogota.gov.co/dataset/4fc8d7c1-fd28-4c77-a5fb-f31bc6fc47ad